

# Metaheurísticas

## Seminario 2. Problemas de optimización con técnicas basadas en búsqueda local

---

### 1. Problema de Maximizar la Influencia en Redes Sociales (SNIMP)

- Definición del Problema
- Ejemplo de Aplicación
- Análisis del Problema
- Solución Greedy
- Búsquedas por Trayectorias Simples
- Casos del problema.
- Agradecimientos

# Definición del Problema

---

**55%** 

**of consumers learn about  
brands or companies on  
social media**

**78%**  
Gen Z


**61%**  
Millenials

**56%**  
Gen X

**35%**  
Baby Boomers

# Definición del Problema

---



# Definición del Problema

---

## Influencer Marketing Stats

**90%**

of consumers trust  
peer recommendations



User generated  
content is

**50%**

more trusted by  
internet users than  
traditional media

Consumers  
are

**71%**

more likely to make a  
purchase based on  
social media referrals




**81%**

of U.S. consumers trust  
advice and information  
from blogs

# Definición del Problema

## 54% of Americans Get (Mis)informed on Social Media

Share of U.S. adults who regularly get news on the following social media platforms



10,658 U.S. adults surveyed Jul-Aug 2024


Source: Pew Research Center



# Definición del Problema

---

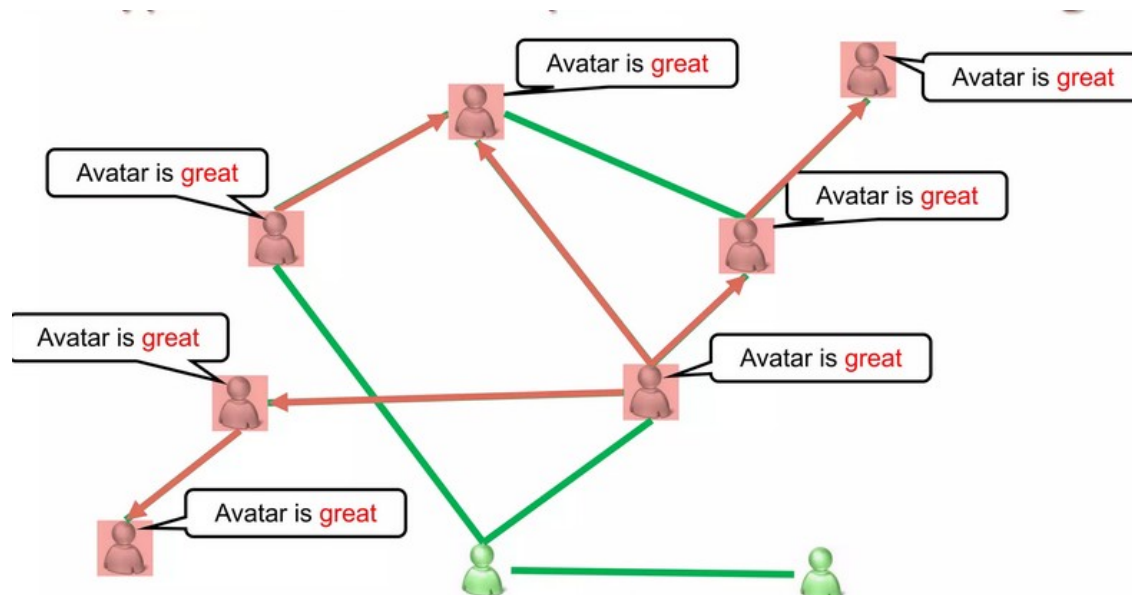
## HOW EFFECTIVE IS INFLUENCER MARKETING?



# Definición del Problema

## ■ Social Network Influence Maximization Problem, SNIMP

*Encontrar los  $K$  usuarios más influyentes en una red social, simulando un modelo de difusión de influencia.*




# Utilidades del Problema

---

■ Márketing digital.



■ Modelos epidémicos





# Definición del Problema

---

- El Problema de Maximizar la Influencia en Redes Sociales, *Social Networks Influence Maximization Problem*, SNIMP, es un problema de optimización combinatoria con una formulación sencilla pero una resolución compleja (**es NP-completo**).
- El problema general consiste en seleccionar un subconjunto  $Sel$  de  $m$  elementos ( $|M|=m$ ) de un conjunto inicial  $S$  de  $n$  elementos (obviamente,  $n > m$ ) de forma que se **maximice** la influencia entre los elementos escogidos.
- Además de los  $n$  elementos ( $e_i, i=1,...,n$ ) y el número de elementos a seleccionar  $m$ , se dispone de una matriz  $C=(C_{ij})$  de dimensión  $n \times n$  no simétrica que contiene las conexiones entre los nodos de la red.
- $C$  puede ser bastante dispersa, con un número muy variable de conexiones para cada nodo.

# Definición del Problema SNIMP

---

- Para el problema **con el que trabajaremos en prácticas**, se busca lo siguiente:

$$s^* \leftarrow_{s \in S} \max ICM(G, S, p, ev)$$

- G es el grafo del problema.
- S es el conjunto de posibles combinaciones.
- p es la probabilidad de influencia/contagio (p=0.01)
- ev es el número de simulación del ICM (ev=10)

# Definición del Problema SNIMP

---

**Algorithm 1**  $ICM(G = (V, E), S, p, ev)$

---

```
1:  $I \leftarrow \emptyset$ 
2: for  $i \in 1 \dots ev$  do
3:    $A^* \leftarrow S$ 
4:    $A \leftarrow S$ 
5:   while  $A \neq \emptyset$  do
6:      $B \leftarrow \emptyset$ 
7:     for  $v \in A$  do
8:       for  $(u, v) \in E$  do
9:         if  $rnd(0, 1) \leq p$  then
10:           $B \leftarrow B \cup \{u\}$ 
11:        end if
12:      end for
13:    end for
14:     $A^* \leftarrow A^* \cup B$ 
15:     $A \leftarrow B$ 
16:  end while
17:   $I \leftarrow I + |A^*|$ 
18: end for
19: return  $I/ev$ 
```

$A^*$  es el conjunto de nodos activados, I su tamaño

B es el conjunto de nuevos nodos

Por cada vecino de cada nodo en A se comprueba si se ha infectado

Se añaden los nuevos.

En la siguiente iteración se van a explorar los vecinos de los nuevos nodos *influidos*

Se devuelve el promedio de nodos infectados en las 10 iteraciones del bucle

---

# Solución Greedy

---

I. Lozano-Osorio, J. Sánchez-Oro, A. Duarte, y O. Córdón, "A quick GRASP-based method for influence maximization in social networks", J Ambient Intell Human Comput, vol. 14, n. 4, pp. 3767-3779, abr. 2023, doi: 10.1007/s12652-021-03510-4.

- La mayoría de propuestas abordadas son Greedy.
- Hay varias definiciones.
- Vamos a usar una de las más sencillas que ofrece un buen resultado según experimentos:

*Añadir secuencialmente el elemento no seleccionado que presente un mayor número de vecinos y vecinos de éstos*

# Solución Greedy

---

## ALGORITMO GREEDY:

```
1:  $S \leftarrow \emptyset$ 
2:  $CL \leftarrow V$ 
3:  $v_0 \leftarrow \text{SelectRandom}(CL)$ 
4:  $S \leftarrow S \cup \{v_0\}$ 
5:  $CL \leftarrow CL \setminus \{v_0\}$ 
6: while  $|S| < m$  do
7:    $RCL \leftarrow CL$ 
8:    $u \leftarrow \arg \min_{v \in RCL} g(v)$ 
9:    $S \leftarrow S \cup \{u\}$ 
10:   $CL \leftarrow CL \setminus \{u\}$ 
11: end while
12: return  $S$ 
```

**Solución Inicial**

**Aplicar heurística**

# Solución Greedy

---

1) Se calcula para cada nodo  $u$  el número de nodos vecinos:

$$d^+(u) = |N_u^+|, N_u^+ = \{v \in V : (u, v) \in E\}$$

2) Se define como valor heurístico de un nodo el total de vecinos, y vecinos de éstos:

$$g(u) = d_u^+ + s \sum_{v \in N_u^+} d_v^+$$

3) Se listan los valores posibles ordenados por su valor heurístico.

4) Se escogen los  $k$  primeros.

# Búsquedas por Trayectorias Simples:

## Búsqueda Local del Mejor

---

- **Representación:** Problema de selección: un conjunto  $Se/\!=\{s_1, \dots, s_m\}$  que almacena los  $m$  elementos seleccionados de entre los  $n$  elementos del conjunto  $S$

Para ser una solución candidata válida, tiene que **satisfacer las restricciones (ser un conjunto de tamaño  $m$ )**:

- No puede tener elementos repetidos
- Ha de contener exactamente  $m$  elementos
- El orden de los elementos no es relevante

# Búsquedas por Trayectorias Simples:

## Búsqueda Local del Mejor

---

- **Operador de vecino de intercambio y su entorno:** El entorno de una solución  $Sel$  está formado por las soluciones accesibles desde ella a través de un movimiento de intercambio

Dada una solución (conjunto de elementos seleccionados) se escoge un elemento y se intercambia por otro que no estuviera seleccionado ( $Int(Sel, i, j)$ ):

$$Sel = \{s_1, \dots, i, \dots, s_m\} \Rightarrow Sel' = \{s_1, \dots, j, \dots, s_m\}$$

- $Int(Sel, i, j)$  verifica las restricciones: si la solución original  $Sel$  es factible y el elemento  $j$  se escoge de los no seleccionados en  $Sel$ , es decir, del conjunto  $S - Sel$ , siempre genera una solución vecina  $Sel'$  factible



# Búsquedas por Trayectorias Simples:

## Búsqueda Local del Mejor

---

- Su aplicación provoca que el tamaño del entorno sea demasiado grande ( $m!$ ),  $m=10 \Rightarrow$  más de 3 millones combinaciones.
- La BL del Mejor del MDP explora todo el vecindario, las soluciones resultantes de los  $m \cdot (n-m)$  intercambios posibles, escoge el mejor vecino y se mueve a él siempre que se produzca mejora
- Si no la hay, detiene la ejecución y devuelve la solución actual
- El método funciona bien pero es muy lento incluso para casos no demasiado grandes.
- Vamos a probar también parar cuando tras  $N_{\text{vecinos}}$  no mejore ( $N_{\text{vecinos}}=50$ ).

# Casos del Problema

---

- Se utilizarán 4 casos reales seleccionados de varios de los conjuntos de instancias del Stanford *Large Network Dataset Collection*:

<https://snap.stanford.edu/data/index.html>.

- Se podría usar esos ficheros, pero hemos modificado y puesto en PRADO una versión sin los nodos sin conexiones, para agilizar y reducir el uso de memoria.
- No planteamos el óptimo, porque en la mayoría de los casos no se conocen, compararemos directamente los valores obtenidos de la función objetivo.
- Para el MDDP, disponemos de cuatro conjunto de datos:
  - **Ca-GrCQc**: Relación de autores en revista científica, tiene 5 242 nodos y 14 496 enlaces.
  - **P2p-Gnutella05**: Intercambio de mensajes en una red social el 5 Agosto 2002, tiene 8846 nodos, y 31 839 enlaces.
  - **P2p-Gnutella08**: Intercambio de mensajes en una red social el 8 Agosto 2002, tiene 6301 nodos, y 20 777 enlaces.
  - **P2p-Gnutella25**: Intercambio de mensajes en una red social, 25 Agosto 2002, tiene 22 687 nodos, y 54 705 enlaces.

# La Biblioteca MDPLIB

---

- El **formato de los ficheros de datos** es un fichero de texto con la siguiente cabecera:

```
# Directed graph (each unordered pair of nodes is saved once): NombreFichero.txt  
# Descripción  
# Nodes: N Edges: E  
# FromNodeId ToNodeId  
u1 v1  
u2 v2
```

- *Donde  $N$  es el número de elementos,  $E$  es el número de conexiones.*
- A continuación aparecen los pares de valores  $(u, v)$  pertenecientes a  $E$ . La matriz de conexiones es una matriz dispersa, por lo que solo se guardan las conexiones con valor de 1.

# La Biblioteca MDPLIB

---

## EJEMPLO: FICHERO DEL CASO *ca-GrQc.txt*:

```
#....  
# FromNodeId  ToNodeId  
0    1  
0    2  
0    3  
0    4  
0    5  
0    6  
0    7  
0    8  
4    9  
4    0  
4   10  
...  
4410  370  
4974  4973  
4974  4976  
1189  1061  
1189  1176  
1189  1177
```

# Agradecimientos

---

- Para la preparación de las transparencias de presentación del problema MDDP se han usado material de los profesores.
  - Isaac Lozano-Osorio. Universidad Rey Juan Carlos
  - Jesús Sánchez-Oro. Universidad Rey Juan Carlos
  - Abraham Duarte. Universidad Rey Juan Carlos
  - Óscar Cordón. Universidad de Granada.
- Otra referencia que me ha servido muy útil:

Y. Ye, Y. Chen, y W. Han, «Influence maximization in social networks: Theories, methods and challenges», Array, vol. 16, p. 100264, dic. 2022, doi: [10.1016/j.array.2022.100264](https://doi.org/10.1016/j.array.2022.100264).
- Además, agradecimientos a Óscar por introducirme al problema.